

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ
ΥΠΟΛΟΓΙΣΤΩΝ



ΕΥΦΥΗΣ ΕΛΕΓΧΟΣ

Intrinsic Motivation in Continuous Control Environments

Instructor: Konstantinos Chatzilygeroudis

Όνομα	Επώνυμο	Αριθμός Μητρώου
ΝΙΚΟΛΑΟΣ	ΒΕΜΗΣ	1083916
ΓΕΩΡΓΙΟΣ	ΣΟΥΚΑΡΑΣ	1092582

Σκοπός

Σκοπός αυτής της εργασίας καθίσταται η υλοποίηση μιας στρατηγικής “intrinsic motivation” προς ενθάρρυνση της διαδικασίας του exploration σε sparse-reward περιβάλλοντα με συνεχήs ενέργειες. Προς επίτευξη αυτού του σκοπού και κατανόηση των αποτελεσμάτων γίνεται σύγκριση με προηγούμενες συμβατικές μεθόδους RL σε περιβάλλοντα όπως είναι το Pendulum και το Swimmer. Ο λόγος που μπαίνουμε στην διαδικασία να επιδιώξουμε ένα τέτοιο αποτέλεσμα είναι πως για σύνθετα περιβάλλοντα με υψηλών διαστάσεων παρατηρήσεις η σύγκλιση των συμβατικών αλγορίθμων είναι αρκετά αργή, παρά τις αρχικές προσπάθειες για βελτίωση όπως είναι η προσθήκη θορύβου στις παραμέτρους νευρωνικού δικτύου (δίκτυο που αντιπροσωπεύει την βέλτιστη πολιτική που επιδιώκεται) ή η μεγιστοποίηση της εντροπίας των ενεργειών.

Μαθηματικό υπόβαθρο-Μεθοδολογία

Για αρχή παρατίθεται ένα θεωρητικό μαθηματικό υπόβαθρο για κατανόηση και εξήγηση των αποτελεσμάτων του “intrinsic motivation”:

Η ενισχυτική μάθηση (Reinforcement Learning - RL) βασίζεται σε μοντέλα τύπου Markov Decision Processes (MDPs), τα οποία ορίζονται ως πλειάδες $M(S, A, P, R, \gamma)$, όπου:

- S είναι το σύνολο πεπερασμένων καταστάσεων (states),
- A το σύνολο ενεργειών (actions) με $k > 1$,
- P είναι η πιθανότητα μετάβασης σε νέα κατάσταση s' δεδομένου πως βρίσκεται στην s και ακολουθεί την ενέργεια a : $P(s' | s, a)$,
- R είναι η συνάρτηση ανταμοιβής: $R(s, a, s')$,
- $\gamma \in [0,1)$ είναι ο παράγοντας έκπτωσης.

Ο πράκτορας ακολουθεί μια πολιτική π , η οποία ορίζει την πιθανότητα επιλογής μιας ενέργειας a σε μια κατάσταση s : $\pi(a | s)$. Σκοπός του πράκτορα είναι να μάθει την πολιτική που μεγιστοποιεί τη συνολική αναμενόμενη απόδοση από κάθε κατάσταση s .

Η αναμενόμενη απόδοση μιας πολιτικής π από την κατάσταση s ορίζεται ως:

$$V_{\pi}(s) = E[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) | s_0 = s],$$
 όπου η διαδικασία που ακολουθείται σκοπεύει στην μεγιστοποίηση της απόδοσης αυτής και άρα η βέλτιστη value function καθίσταται η $V_{\pi^*}(s) = \sup_{\pi} V_{\pi}(s)$. Προς επίτευξη αυτού του σκοπού προσπαθούμε να προσδιορίσουμε τη βέλτιστη πολιτική ως $\pi^*(s) = \operatorname{argmax}_a Q^*(s, a)$,

με $Q(s) = E_{s' \sim P_{sa}(\cdot)}[R(s, a, s') + \gamma V_{\pi}(s')]$. Βέβαια αυτή η βέλτιστη πολιτική μπορεί να μην είναι μοναδική.

Ενστικτωδώς θα προσπαθούσαμε να βελτιώσουμε την διαδικασία μάθησης προσθέτοντας κάποιου είδους rewards που ιδανικά θα καθοδηγήσουν τον αλγόριθμο να μάθει μια καλή πολιτική πιο γρήγορα.

Η προσθήκη μιας νέας συνιστώσας στο σήμα ανταμοιβής (reward shaping) μπορεί να τροποποιήσει τη συνάρτηση R σε νέα R' :

$$R'(s, a, s') = R(s, a, s') + F(s, a, s')$$

Ο στόχος είναι να οριστεί μια τέτοια συνάρτηση F ώστε η βέλτιστη πολιτική να παραμείνει αμετάβλητη (policy invariance). Δηλαδή αναζητούμε ένα είδος reward-function

$F: S \times A \times S \rightarrow \mathbb{R}$ που εγγυάται πως η βέλτιστη πολιτική στο $M' (S, A, P, R+F, \gamma)$ θα είναι ίδια και στο M .

Η απάντηση στηρίζεται στο θεώρημα της Απαραλλακτικής Πολιτικής (Policy Invariance Theorem). Το θεώρημα απαντά στο ερώτημα: ποια μορφή της προσθετικής συνάρτησης ανταμοιβής (reward shaping) αφήνει αμετάβλητη την ιδανική πολιτική; Το θεώρημα ορίζει ότι η μοναδική μορφή της $F(s, a, s')$ που διατηρεί την πολιτική αμετάβλητη είναι η εξής:

$$F(s, a, s') = \gamma \cdot \Phi(s') - \Phi(s),$$

$\Phi: S \rightarrow \mathbb{R}$ τέτοια ώστε για κάθε $s \in S - \{s_0\}$, $a \in A$, $s' \in S$ είναι μια αυθαίρετη συνάρτηση δυναμικού (potential function), και γ είναι ο παράγοντας έκπτωσης. Αυτή η συνάρτηση F ονομάζεται potential-based shaping. Αξίζει να υποδειχθεί πως αν πρέπει να επιλεγεί μια Φ για την κατασκευή της potential-based shaping function πρέπει η Φ να είναι φραγμένη ώστε να είναι και η F . Ας σημειωθεί ότι για την περίπτωση των πεπερασμένων καταστάσεων που εξετάζεται βέβαια, αυτή είναι μια κενή συνθήκη, δεδομένου ότι η F , έχοντας ένα εύρος πεπερασμένης πληθικότητας, θα ήταν αυτομάτως φραγμένη.

Απόδειξη:

Έστω ένα Markov Decision Process (MDP) με αρχική συνάρτηση ανταμοιβής $R(s, a, s')$ και μια νέα συνάρτηση ανταμοιβής R' η οποία περιλαμβάνει επιπλέον ένα όρο shaping της μορφής:

$$R'(s, a, s') = R(s, a, s') + F(s, a, s')$$

Θεωρούμε ότι το F έχει τη μορφή δυναμικού (potential-based):

$$F(s, a, s') = \gamma \cdot \Phi(s') - \Phi(s)$$

Θέλουμε να δείξουμε ότι η νέα συνάρτηση απόδοσης $V'\pi(s)$ είναι ίση με την αρχική $V\pi(s)$ συν μια σταθερή μετατόπιση που εξαρτάται μόνο από την κατάσταση εκκίνησης και όχι από την πολιτική.

Η απόδοση της πολιτικής π με βάση την τροποποιημένη ανταμοιβή είναι:

$$V'\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) \mid s_0 = s \right]$$

$$= \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t (R(s_t, a_t, s_{t+1}) + F(s_t, a_t, s_{t+1})) \mid s_0 = s \right]$$

$$= V\pi(s) + E\pi \left[\sum_0^\infty \gamma^t (\gamma \cdot \Phi(s_{t+1}) - \Phi(s_t)) \mid s_0 = s \right]$$

Διαχωρίζοντας τους όρους:

$$\begin{aligned} &= V\pi(s) + E\pi \left[\sum_0^\infty \gamma^{t+1} \Phi(s_{t+1}) - \gamma^t \Phi(s_t) \right] \\ &= V\pi(s) + E\pi \left[-\Phi(s_0) + \gamma \Phi(s_1) - \gamma \Phi(s_1) + \gamma^2 \Phi(s_2) - \dots \right] \end{aligned}$$

Η άθροιση αυτή είναι τηλεσκοπική και τα ενδιάμεσα ακυρώνονται:

$$= V\pi(s) + \left(\lim_{t \rightarrow \infty} \gamma^t \Phi(s_t) \right) - \Phi(s_0)$$

Υποθέτοντας ότι η Φ είναι φραγμένη και ότι $\gamma \in [0,1)$, τότε:

$$\lim_{t \rightarrow \infty} \gamma^t \Phi(s_t) \rightarrow 0$$

Άρα:

$$V'\pi(s) = V\pi(s) - \Phi(s_0)$$

Η μετατόπιση είναι ανεξάρτητη από την πολιτική π . Συνεπώς:

$$\operatorname{argmax}_\pi V'\pi(s) = \operatorname{argmax}_\pi (V\pi(s) - \Phi(s)) = \operatorname{argmax}_\pi V\pi(s)$$

Άρα η βέλτιστη πολιτική παραμένει η ίδια υπό το potential-based shaping. Ωστόσο αυτή η απόδειξη πρόκειται για την ικανή συνθήκη πως κάθε βέλτιστη πολιτική στο M' είναι και βέλτιστη πολιτική στο M (και αντίστροφα). Για την αναγκαία συνθήκη δηλαδή πως αν η F δεν είναι potential-based shaping function τότε υπάρχουν κατάλληλες $T, R: S \times A \rightarrow \mathbb{R}$ ώστε καμία βέλτιστη πολιτική στο M να είναι και στο M' .

Για να αποδείξουμε την αναγκαιότητα της μορφής shaping ανταμοιβής:

$$F(s, a, s') = \gamma \cdot \Phi(s') - \Phi(s)$$

υποθέτουμε ότι υπάρχει κάποια γενικότερη συνάρτηση $F(s, a, s')$ η οποία διατηρεί τη βέλτιστη πολιτική αμετάβλητη για κάθε MDP. Θέλουμε να δείξουμε ότι τότε αναγκαστικά η F πρέπει να είναι της παραπάνω μορφής.

Η απόδειξη βασίζεται σε μεθοδολογία «αντιπαράδειγματος». Δηλαδή, αν F δεν έχει τη μορφή δυναμικού, τότε μπορούμε να κατασκευάσουμε ένα πολύ απλό MDP (με δύο καταστάσεις και κατάλληλες ανταμοιβές), στο οποίο η εφαρμογή αυτής της F αλλάζει τη βέλτιστη πολιτική.

Αποδεικνύεται ότι οποιοσδήποτε διαφορετικός τύπος για το F , που δεν μπορεί να γραφεί ως διαφορά δυναμικού μεταξύ καταστάσεων, μπορεί να προκαλέσει αλλαγή στη σειρά προτίμησης των ενεργειών.

Συγκεκριμένα, εάν $F(s, a, s') \neq \gamma \cdot \Phi(s') - \Phi(s)$, τότε για κάποιες πολιτικές π_1 και π_2 θα ισχύει:

$$V\pi_1(s) > V\pi_2(s) \text{ αλλά } V'\pi_1(s) < V'\pi_2(s)$$

δηλαδή, η μεταβολή στη συνάρτηση ανταμοιβής μεταβάλλει τη διάταξη προτίμησης μεταξύ πολιτικών, άρα και τη βέλτιστη πολιτική.

Π.χ. Έστω οι καταστάσεις $S = \{s_1, s_2\}$ και οι ενέργειες $A = \{a_1, a_2\}$. Από την κατάσταση s_1 , αν ο πράκτορας επιλέξει την a_1 , μεταβαίνει στην κατάσταση s_2 με ανταμοιβή $R(s_1, a_1, s_2) = 0$. Αν επιλέξει a_2 , παραμένει στο s_1 με ανταμοιβή $R(s_1, a_2, s_1) = 1$. Η κατάσταση s_2 είναι τελική.

Χωρίς οποιοδήποτε shaping, η ενέργεια a_2 είναι προτιμότερη, γιατί δίνει άμεσα ανταμοιβή 1, ενώ η a_1 δίνει 0.

Ας υποθέσουμε τώρα ότι εφαρμόζεται ένα σχήμα shaping που δεν έχει τη μορφή:

$$F(s, a, s') = \gamma \cdot \Phi(s') - \Phi(s)$$

π.χ. θέτουμε:

$$F(s_1, a_1, s_2) = 2, F(s_1, a_2, s_1) = 0$$

Η νέα συνολική ανταμοιβή γίνεται:

$$R'(s_1, a_1, s_2) = 0 + 2 = 2$$

$$R'(s_1, a_2, s_1) = 1 + 0 = 1$$

Άρα τώρα η ενέργεια a_1 είναι καλύτερη με βάση τη νέα ανταμοιβή, και η βέλτιστη πολιτική αλλάζει

Κατά συνέπεια, για να διατηρείται απaráλλακτη η βέλτιστη πολιτική για όλα τα MDPs, το F πρέπει να έχει τη μορφή potential-based shaping. Άρα, η μορφή $F(s, a, s') = \gamma \cdot \Phi(s') - \Phi(s)$ είναι αναγκαία και ικανή συνθήκη για policy invariance.

Πειράματα και αποτελέσματα:

Για τα πειράματα που ακολουθούν χρησιμοποιήθηκαν novelty-based intrinsic rewards και συγκεκριμένα random network distillation, όπου το intrinsic reward είναι η απόλυτη διαφορά μεταξύ ενός target και ενός predictor network (μετά τη βελτιστοποίηση της πολιτικής του αλγορίθμου βελτιστοποιείται και το νευρωνικό δίκτυο του predictor ελαχιστοποιώντας συνάρτηση τετραγωνικού σφάλματος). Ας εξετάσουμε τώρα αν σε αυτή την περίπτωση πληρούνται οι προϋποθέσεις για να είναι potential based shaping function:

Pendulum-Swimmer: Ο χώρος καταστάσεων είναι συνεχής και ορίζεται ως τρισδιάστατο διάνυσμα $[\cos(\theta), \sin(\theta), \theta']$, όπου κάθε τιμή είναι φραγμένη αφού $(\cos(\theta), \sin(\theta)) \in [-1, 1]$ και η παράγωγος είναι φραγμένη για να μην γίνονται απότομες κινήσεις. Άρα $\|f(s) - f^*(s)\|^2$, είναι φραγμένη δεδομένου πως έχουμε γραμμικά μοντέλα με συναρτήσεις ενεργοποίησης Relu. Ως επακόλουθο έχουμε πως και η F είναι φραγμένη και

άρα πληρούνται οι προδιαγραφές για την εύρεση της βέλτιστης πολιτικής με προσθήκη intrinsic reward.

Πριν παρουσιαστούν οι μέθοδοι αξίζει να σημειωθεί πως έχει χρησιμοποιηθεί κοινό seed σε κάθε αλγόριθμο ώστε να μην υπάρχει μεγάλη εξάρτηση από αρχικές συνθήκες.

Ως πρώτο πείραμα αναδεικνύεται αυτό του Pendulum, που πρόκειται για σταθεροποίηση του σε κατακόρυφη θέση δεδομένου πως ξεκινάει σε τυχαία αρχική θέση και εφαρμόζουμε κατάλληλες ροπές προς επίτευξη αυτού του στόχου. Για να γίνουν πιο σαφή τα αποτελέσματα που εξάχθηκαν έχει προστεθεί σημαντικός θόρυβος (Gaussian με μέση τιμή μηδέν και διασπορά 0.5) στην κατάσταση η οποία ανιχνεύεται από τον αντίστοιχο πράκτορα. Οι αλγόριθμοι που παρουσιάζονται είναι: Q-learning(επειδή πρόκειται για συνεχή χώρο ενεργειών έχει συμπεριληφθεί και πυκνή δειγματοληψία ώστε να είναι συμβατό), PPO(proximal policy optimization, actor-critic και on-policy), entropy maximization, noise-based exploration σε DDPG(καθώς συμβατικά δεν θα μπορούσε να αντικατοπτρίσει την στοχαστική συμπεριφορά της κατάστασης) και τέλος RND + PPO.

Η λογική του entropy maximization ανάγεται αρχικά στην εντροπία κατά Shannon, όπου δεδομένου διακριτή τυχαία μεταβλητή X που μπορεί να είναι οποιοδήποτε στοιχείο x του συνόλου $\mathbf{X}$ και είναι κατανεμημένο με βάση το $p: \mathbf{X} \rightarrow [0,1]$, είναι

$$H(X) = - \sum_{x \in \mathbf{X}} p(x) \log(p(x))$$
 (για συνεχή χώρο ενεργειών έχουμε αντίστοιχα ολοκλήρωμα αντί για άθροισμα)


Αλλιώς πρόκειται για την αναμενόμενη τιμή του $-\log(p(X))$ ($E[-\log(p(X))]$). Δεδομένου πως έχουμε συνάρτηση πληροφορίας $I(p)$, η προηγούμενη σχέση δηλαδή το μέγεθος της πληροφορίας που έχει αποκτηθεί λόγω παρατήρησης ενός γεγονότος έχει εξαχθεί υπό τις εξής προϋποθέσεις:

- 1) Η $I(p)$ μειώνεται μονοτονικά ως προς το p : η αύξηση της πιθανότητας ενός γεγονότος μειώνει την πληροφορία από ένα παρατηρούμενο γεγονός και αντίστροφα.
- 2) $I(1) = 0$: γεγονότα που συμβαίνουν πάντα δεν μεταδίδουν πληροφορίες.
- 3) $I(p_1 * p_2) = I(p_1) + I(p_2)$: η πληροφορία που λαμβάνεται από ανεξάρτητα γεγονότα είναι το άθροισμα της πληροφορίας που λαμβάνεται από κάθε γεγονός.
- 4) Το $I(p)$ είναι μια δύο φορές συνεχώς διαφορίσιμη συνάρτηση του p .

Είναι εφικτό λοιπόν να αξιοποιηθεί τέτοιου είδους εντροπία ως επιπλέον επιβράβευση για επιπλέον exploration.


Μια τελευταία επισήμανση πριν τα αποτελέσματα είναι πως ο θόρυβος του DDPG έχει προστεθεί όχι στο action space αλλά στις παραμέτρους του νευρωνικού έτσι ώστε οι ενέργειες που ακολουθούνται να είναι άμεσα αποτελέσματα των παρατηρήσεων.

Τα αποτελέσματα που εξάχθηκαν για 500 επεισόδια είναι τα εξής:



Ως δεύτερο πείραμα θεωρήθηκε το Swimmer όπου προσπαθούμε το μοντέλο μας να ακολουθήσει μια γραμμική πορεία κίνησης στο άξονα x εντός νερού κουνώντας τα άκρα του. Οι αλγόριθμοι που συγκρίνονται είναι: noise-based exploration σε DDPG και όπως πριν PPO+RND. Μια σημαντική διαφορά με πριν παρακολουθώντας χαρακτηριστικά που καταγράφονταν όπως το `entropy_loss`, ακολουθήθηκε μια περιοδική προσέγγιση δημιουργίας intrinsic reward καθώς παρατηρήθηκε πως αλλιώς απόσβενε πολύ γρήγορα χωρίς να έχει γίνει επαρκές exploration και κατόπιν συνέβαλε μόνο το intrinsic κομμάτι.

Τα αποτελέσματα που εξάχθηκαν για 500 επεισόδια είναι τα εξής:



Συμπεράσματα

Παρατηρούμε πως και στις δύο περιπτώσεις που πρόκεινται για παραδείγματα σύνθετων περιβαλλόντων με υψηλών διαστάσεων παρατηρήσεις η σύγκλιση με χρήση intrinsic motivation είναι καλύτερη (πιο γρήγορα εντοπίζεται η βέλτιστη πολιτική) σε σχέση με τυπικές μεθόδους RL.